

AGENTLOOPGATE：面向智能体执行框架的证据治理进化与失效闭合选择

JiaoyangLi

jiaoyanglily@gmail.com

<https://github.com/jiaoyangli-shadow7day/AgentLoopGate>

草稿 – 2026 年 8 月

摘要

语言模型智能体可以根据执行失败修改提示词、工具、路由和控制流，但产生一个执行框架改动，并不等于已经证明该改动应当发布。聚合分数可能掩盖能力交换，重试和缺失轨迹可能污染分母，优化器也可能在耦合数据上评估自己的提案。本文提出 AGENTLOOPGATE：一个与运行时无关的发布治理层。它保留宿主原生轨迹、持久化和遥测能力，同时把证据、成本和谱系绑定到冻结的目标、数据切分、评估器、定价和门禁。外部更新器可以提出候选方案，但晋升仍由人类控制。P0-R14 的事故被作为系统形成证据，而不是合并的有效性证据。在一个冻结的 Banking 验证中，我们将 DeepSeek Harness 与外部 Agentic Harness Engineering 更新器结合，执行了全部 125 个获授权的预发布位置。基线与三个候选在相同 Selection 任务上的得分分别为 6/15、6/15、5/15 和 6/15。每个候选都获得任务 017，却同时退化了基线成功任务 062 和 095；所有配对 95% bootstrap 区间均包含零。因此 AGENTLOOPGATE 对所有候选返回 HOLD，且没有发起任何 Release 调用。已知模型成本精确为 3.908664788 美元，不存在未知模型成本范围。无模型夹具还确认了插件与 DeepSeek Harness 持久化及 OpenTelemetry 的共存。本文不主张获得了正向自进化效果；结果表明，失效闭合、任务配对的治理能够让“放弃发布”成为可审计的科学结论。

1 引言

智能体执行框架把语言模型变成能够观察状态、调用工具、保存记忆、恢复会话并与用户交互的系统。近期工作通过语言反思 [10, 7]、学习提示词与流水线参数 [4]、函数级优化 [13]，或对智能体程序执行自动搜索 [3] 来改

进此类系统。这些方法拓宽了可被修改的范围，但它们本身并没有规定：一项改动需要什么证据才足以发布。

这一差异在有状态、使用工具的场景中尤其重要。候选方案可能在保持聚合分数不变的同时，用一种能力交换另一种能力；重试可能掩盖失败尝试及其成本；缺失轨迹或评估器事故可能悄然缩小分母；同一批数据也可能从诊断泄漏到选择。最后，可观测性数据可以帮助调试，却未必完整到足以充当发布证据。

我们提出 AGENTLOOPGATE，一个独立的证据治理与进化决策层。它不是另一套运行时、轨迹后端或自动部署系统。宿主原生执行日志仍然是“发生了什么”的事实来源。AGENTLOOPGATE 增加可验证引用、不可变评测身份、受限更新器输入、独立的基线配对选择，以及返回 SHIP-RECOMMENDED、HOLD 或 REJECT 的字典序门禁。人类仍是唯一的晋升授权者。

本文有四项贡献：

1. 提出与运行时无关的证据模型，在不替换原生持久化或遥测的前提下，把宿主轨迹绑定到归一化运行、候选、快照、成本与决策；
2. 提出失效闭合的进化协议，将诊断、Update-Check、基线配对 Selection 与条件式 Release 分离，并精确记录尝试与成本；该协议由可审计的 P0-R14 失败序列及版本化控制逐步形成；
3. 提供原生 DeepSeek Harness 插件，消费公开会话事件、对账 flush 快照、保留 JSONL/SQlite 与 OpenTelemetry，并将治理故障与智能体回合隔离；
4. 给出完整封存的 Banking 研究，显示两个聚合平局实际上都隐藏了“两个增益换两个退化”的能力交换，因此正确的系统结论是放弃发布。

本文的经验主张有意保持狭窄：AGENTLOOPGATE 发现了证据不足的进化，并在 Release 之前阻止了它。我

们不主张外部更新器改进了智能体，不主张结果可推广到 Banking 之外，也不把夹具延迟解释为生产负载。

2 问题与设计目标

设 A_0 为冻结的基线执行框架，外部更新器根据受限失败包产生候选 $C_1, \dots, C_m$ 。对冻结 Selection 群体中的任务 t ， $y_t(A) \in \{0, 1\}$ 表示执行框架 A 下的稳定成功。发布问题不只是 $\arg \max_A \sum_t y_t(A)$ 。只有当证据群体完整，且新增能力没有牺牲受保护的基线行为时，候选才应具备资格。

目标。 系统应当：(i) 接收来自多种更新器家族的提案，而不信任更新器自带分数；(ii) 保持诊断、选择和发布数据互不交叉；(iii) 让每项结论都可追溯到不可变的任务、运行、候选、快照与定价身份；(iv) 把重试、超时、未知成本和基础设施无效作为一等事实；(v) 保留宿主运行时的原生行为；(vi) 让放弃成为成功的终止结果。

非目标。 AGENTLOOPGATE 不训练模型权重、不认证智能体安全、不替换宿主日志、不提供轨迹用户界面，也不部署被选中的候选。Banking 是参考验证包，而不是产品边界。

信任边界。 可信内核包含模式、规范序列化、内容哈希、切分强制、评估器接口、候选注册表、尝试与成本账本，以及门禁。更新器工作区和可变执行框架资产不受信任。原始模型文本、用户模拟和外部遥测不能自行声明成功。

3 系统设计

3.1 证据平面

证据路径分为四个平面。H0 是宿主原生事实来源，即 DeepSeek Harness 仅追加会话日志或基准原始结果。L0 保存 *SourceTraceRef* 和脱敏证据回执。L1 保存归一化的运行、工具、状态、延迟、用量与成本事实。L2 保存评测工件，包括失败包、候选与快照清单、批次汇总、统计、谱系和决策。每个对象使用规范 JSON 或 YAML 以及 SHA-256 摘要。正式结论必须沿该链返回 H0。

遥测不会被刻意提升为评测真值。OpenTelemetry 是面向轨迹、指标和日志的厂商中立框架 [8]；导出器可能有用，也可能缺失、被采样或被重新配置。因此 AGENTLOOPGATE 与 OTel 共存，但把完整性建立在宿主会话事件流和认证回执上。

3.2 冻结身份与不可变生命周期

正式实验会冻结目标、六个隔离任务池、评估器、定价、运行时固定版本、协议、研究计划、源代码修订和基线快照。每个付费操作先写入持久的 STARTED 事件，随后只写入一个终止事件。恢复操作验证已有字节，仅继续尚未执行的工作，不能悄然重跑已经完成的付费位置。

成本包含两个不同问题：有效运行的比较成本是否精确，以及全部已观察尝试表面是否完整。缺失成本只能记为 partial 或 unavailable，绝不能记作零。基础设施无效运行在性能分母之外报告；如果注册覆盖不完整，则阻断整个批次。

3.3 受限外部更新器

更新器只接收由 Update-Source 导出的失败包，以及父快照中列入白名单的可变资产。它不能读取 Selection 或 Release 任务、金标准答案、评估器代码、既往私有决策或可信内核。输出必须经过路径范围、模式、语义差异、运行时能力绑定和谱系验证，之后才能注册。更新器原生顺序作为证据保留，但不构成发布决策。

3.4 基线配对选择与条件式发布

Update-Check 以较低成本拒绝格式错误或明显有害的候选。存活候选与 A_0 随后在完全相同的 Selection 任务上运行。对候选 C ，定义配对差 $d_t = y_t(C) - y_t(A_0)$ 、增益集 $G_C = \{t : d_t = 1\}$ 和退化集 $R_C = \{t : d_t = -1\}$ 。R15 正确性门禁要求


$$\sum_t d_t > 0, \quad R_C = \emptyset, \quad (1)$$

同时还要求证据完整、严重违规为零、重试或超时不增加、p95 延迟比不高于 1.2，且全尝试成本比不高于 1.2。标量分数平局不属于增益。

若没有候选满足全部前提，Selection 返回 HOLD 并禁止 Release 调用。即便选出了候选，Release-ID、Release-OOD 和 Replay 仍需单独绑定的执行授权。最终的 SHIP-RECOMMENDED 也只是建议，而不是部署。

4 DeepSeek Harness 集成

DeepSeek Harness 是由插件组合的智能体运行时，其持久会话日志记录模型上下文、工具调用与生命周期事件 [1]。AGENTLOOPGATE 以树外 Cordis bundle 的形



冻结的目标、切分、评估器、定价、协议和研究身份绑定每次转换。只有 Selection 返回候选且存在独立授权时才创建 Release；晋升永不会自动发生。

图 1: AGENTLOOPGATE 将运行时事实、治理证据、候选生成和发布决策分离。宿主轨迹仍是执行事实来源；内容寻址的治理工件反向引用该轨迹。

式集成到固定的开发者预览修订；没有插件时，Python 核心仍可独立使用。

观察器订阅公开的会话生命周期和事件接口。实时路径提供低延迟回执；每次 flush 都与权威 `session.events` 快照对账，从而恢复构造、续跑或瞬时缓冲区缺口。序列空洞会将证据标记为不完整。插件不会注册竞争性的遥测后端，不查询私有 SQLite 表，也不重写原生 JSONL/SQLite。桥接故障与智能体回合隔离，但会阻止受影响证据进入正式决策。卸载时会移除工具、监听器和桥接子进程。

这种安排让原生轨迹与治理证据互为补充。开发者保留既有会话持久化和 OTel 导出器；AGENTLOOPGATE 只增加内容寻址的来源证明与决策语义。

5 系统形成与失败经验：P0–R14

AGENTLOOPGATE 并非一次设计完成。当前契约来自一系列冻结实验、失败预检、部分批次和事故复盘。仓库的实验身份从 `EXP_BANKING_P0` 直接跳到 `EXP_BANKING_R2`；不存在注册的 `EXP_BANKING_R1` 身份。我们保留这个命名缺口，而不虚构一次运行。P0–R14 也不能合并成有效性曲线，因为不同身份之间的协议、证据模式、基线，有时甚至评估器输入都发生了变化。它们的合理作用是过程证据：哪里失败、系统是否停止、哪些证据得以保留，以及哪个控制在后继版本中成为强制要求。先保证执行完整性，再谈优化。P0–R6 表明：当重试可以逃逸预算、被丢弃的调用可以从成本中消失，或一种回复表示可以把明确意图变成 `Infrastructure Invalid` 时，启动优化器为时过早。因此，这一序列把尝试拓扑、超时归属、回复归一化和直接谱系纳入可信内核。重要的是，恢复出可解析或完整回合并不会改写业务结果；修复后的位置仍可能是有效的任务失败。

先保证决策完整性，再谈发布。R7–R10 把故障边界推向下流。即使执行完整，动态价格查询仍可能产生错误

的精确零，汇总可能读取错误成本平面，损坏的金标准夹具可能污染失败包，Selection 也可能在没有配对基线时强制产生胜者。这些事故形成了 R15 使用的冻结价格权威、评估器版本化、候选语义与能力检查、基线配对 Selection，以及一等 HOLD 语义。

快速失败但不删除证据。R11–R14 检验恢复与停止行为。系统反复保留部分证据，并拒绝填补缺失分母。R13 量化了串行批次中的真实效率故障；R14 随后证明新的位置级停止阻断了剩余队列，同时在 Selection 之前暴露了下一个控制平面缺陷。这正是失效闭合进化的实际含义：失败被保留为证据，而不是为了让实验继续而被隐藏。

综合来看，P0–R14 支持的是系统主张，而非正向进化主张。它们说明架构由可观察失败塑造，并且每个被发现的失败都转化为后继版本中可执行的控制。R15 是由此形成的基线约束预发布策略的第一次完整确认性应用。

6 Banking R15 方法

6.1 参考环境

本研究使用由 τ 系列工具-智能体-用户基准派生的知识密集型 Banking 环境。这类基准评测有状态对话、策略遵循、API 使用和最终环境状态，而不只评测静态文本 [11]。ToolSandbox 也强调有状态工具使用评测 [6]。我们用 Banking 演练完整证据路径，而不是定义 AGENTLOOPGATE 的适用领域。

执行模型与用户模拟器均为冻结运行时参数下的 DeepSeek 端点。外部更新器为提交 `8b2a55d97590363fe50c3cc6b5e833b020a4bb4c` 上的 `agentic-harness-engineering 0.1.0`。正式执行前，基准运行时、协议、研究、源码树、定价与 A_0 均已内容寻址。

轮次	终止证据	暴露的故障	后继保留的控制
P0-R2	P0 以被取代的 HOLD 保存; R2 A4 保留一次失败协议诊断	冻结的单个重试意图与实际调用的运行时默认值不同; 陈旧验收、源码打包、忽略规则和 Linux 异步行为也未通过 clean-room 检查	对执行协议做内容寻址; 以“取代”代替重写; 付费取证前强制执行源码工件与干净检出的 Linux 验证
R3	22/25 个 Update-Source 位置有效; HOLD	外层恢复再次应用每进程重试预算, 且被丢弃的尝试丢失了 User Simulator 成本	全局每位置尝试上限; 仅追加的任务-尝试账本与独立 Agent/User 用量账本; 未知成本绝不记为零
R4	24/25 有效; HOLD; 精确全尝试模型成本 0.6917880208 美元	一个反复出现且可唯一映射的回复包装器仍未被识别	仅当工具身份与参数明确时才做窄白名单归一化; 歧义语法继续失效闭合
R5-R6	R5: 23/25 有效; R6: 24/25 有效; 均为 HOLD。R6 对账得到精确全尝试成本 0.7698343648 美元	仅推理的空最终回复、相同的内外层超时、额外的显式回复形态, 以及间接失败调用谱系	单独记账的同会话“仅最终回复”修复; 有序超时: 直接任务/尝试/会话连接; 不从隐藏推理中推断
R7-R8	R7 完成 Source、创建三个候选并完成 A_0 Check; 首个候选 Check 部分失败。R8 未产生付费调用	动态定价把非零 token 的 User 成本错误算成精确零; 后续审计还发现汇总与门禁读取原始成本而非直接账本成本	用正 token 不变量执行冻结价格重算; 直接成本必须端到端传播到汇总、曲线和最终门禁
R9	25/25 Source 有效; 不可变 HOLD; 精确全尝试成本 0.7015112488 美元	任务 053 的金标准夹具遗漏了必要用户动作, 使正确轨迹看起来错误	确定性的无模型原因隔离; 版本化评估器覆盖层; 证据污染时阻止候选生成
R10	95 个正式位置; 付费 HOLD; 截至 C2 的精确模型成本 3.0651904832 美元	Selection 遗漏 A_0 、强制选出胜者、忽略多项全尝试运行事实、接纳重复候选, 并允许未绑定工具路由	同池基线配对; 一等放弃语义; 全尝试重试/超时/p95/成本输入; 语义去重与运行时能力绑定
R11-R12	R11: 24/25 Source 有效。R12: 34/35 个已执行位置有效; 均为 HOLD。R12 观察到 Provider 成本下界 1.1970712488 美元	失败尝试封存缺少直接谱系; User Simulator 空消息与更新器使用进程全局 /tmp 破坏后继续执行	对已有字节仅验证恢复; 受限的“仅最终回复”User 修复; 尝试局部的更新器运行时与沙箱医生; 每次修复都需新身份
R13	24/25 Source 有效; HOLD。发生永久无效后, 12 个排队位置仍产生 588 次调用, 已知成本 0.4686327800 美元	跨阶段门禁有效, 但串行批次缺少位置级快速失败	重试耗尽后, 在下一位置前停止, 同时保留失败位置、未知成本范围、原生轨迹和不完整分母
R14	执行 46/125 个位置; HOLD; 精确成本 1.4876297096 美元。快速失败阻止 79 个授权位置启动	候选预检检查的是基线字节与补丁 token, 而非物化后的预期字节; 唯一完成的候选 Check 退化了一个基线成功	在隔离树中应用每个补丁并在注册前验证最终字节; 封存一等部门 HOLD; 恢复仅执行验证

表 1: P0-R14 的系统形成。计数和成本是已观察历史证据, 不能作为候选有效性的可比估计。每个后继都保留前序原始证据, 并在执行语义变化时使用新的冻结身份。

6.2 注册的预发布表面

R15 执行了 25 个 Update-Source 位置、40 个 Update-Check 位置 (A_0 加三个候选, 每项各 10 个), 以及 60 个 Selection 位置 (A_0 加三个候选, 每项各 15 个): 九个完整批次共 125/125 个授权位置。所有位置均有效, 没有出现 Infrastructure Invalid 运行。实验不包含 Release 授权。

外部更新器按原生顺序输出三个语义不同的候选, 记为 C1-C3。Selection 以稳定任务成功作为主要终点。延迟、严重违规、重试、超时与全尝试成本是门禁输入, 而不是事后诊断。

6.3 不确定性与多重性

对每个候选, 我们对 15 个配对任务差值 d_t 执行 10,000 次确定性 bootstrap 重采样, 并报告 $\bar{d}$ 的最近秩 95% 区间。bootstrap 种子已预注册, 每次比较都导出内

容绑定的有效种子。统计单位是任务, 而不是试验或模型调用 [2]。区间仅用于描述冻结 Selection 群体: 同一更新器产生的三个提案彼此相关, 因此我们既不提出经多重性校正的优越性主张, 也不做跨领域推断。

6.4 研究问题

我们考察: 独立治理是否发现聚合分数遗漏的任务级能力交换 (RQ1); 当没有候选通过冻结门禁时, 系统是否在 Release 前放弃 (RQ2); 重试和失败期间证据与成本是否保持完整 (RQ3); DeepSeek Harness 插件是否在无头夹具中与原生持久化及 OTel 共存 (RQ4)。

方案	稳定成功	增益	退化	配对 $\bar{d}$ [95% CI]	p95 比	成本比	处置
A_0	6/15	–	–	–	1.000	1.000	基线
C1	6/15	017, 096	062, 095	0.000 [–.267, .267]	1.882	1.121	留置
C2	5/15	017, 090	056, 062, 095	–.067 [–.333, .200]	1.670	1.108	留置
C3	6/15	017, 090	062, 095	0.000 [–.267, .267]	1.652	1.127	留置

表 2: 相同 15 任务群体上的冻结 Selection 结果。成本比使用全部已观察尝试成本；p95 比相对于 A_0 。每个候选都违反了严格增益、零退化和 p95 非劣要求。

7 结果

7.1 聚合平局掩盖了共同退化

C1 与 C3 同 A_0 均为 6/15, C2 为 5/15。这些平局并不代表稳定等价。每个候选都获得任务 017, 并失去相同的基线成功任务 062 与 095; C2 还失去 056。C1 额外获得 096, 而 C2 与 C3 获得 090。因此, 两个聚合平局都代表“两个增益交换两个受保护成功”。所有配对区间均包含零。

运行证据也独立淘汰了每个候选。所有 p95 延迟比都超过 1.2; C1 还增加一次超时。全尝试成本比均在 1.2 内, 但都高于 A_0 。由于式1是前提条件而非加权分数, 较低成本不能补偿退化。

7.2 系统正确地选择了放弃

最终原因是 `no_candidate_passed_baseline_bound_selection_policy`。AGENTLOOPGATE 留置 C1–C3, 把治理候选设为 `null`, 返回 `HOLD`, 并在 Selection 之后产生零次模型调用。不存在 Release-ID、Release-ODD、Replay、晋升或部署工件。这是正常且成功的终态: 系统拒绝从证据不足的候选阶梯中制造一个胜者。

因此, 就治理行为而非候选质量而言, RQ1 与 RQ2 得到肯定回答。独立配对选择把更新器原生排名转化为放弃, 而条件式 Release 边界在前提失败后阻止了额外付费评测。

7.3 证据与成本实现精确对账

九个批次都具备精确记账。调用账本包含 4,378 次终止模型调用、10,343,844 个输入 token、4,648,289 个输出 token、222,019,328 个缓存读取 token、零个未解决调用和零次提供商级重试。任务级重试与超时事实单独保留在批次证据中。正式批次成本为 3.8830976464 美元; 外部更新器调用成本为 0.0255671416 美元; 精确已知模型

成本为 3.9086647880 美元。未知模型成本范围为空。本地计算与 GitHub Actions 的货币成本被明确标记为未计量或不可用, 而不是零。

正式过程墙钟时间为 52,591.59 秒 (14.61 小时)。该时长包含刻意串行、低并发的执行路径, 不应被理解为最短可达运行时间。它证明路径、时长、重试、调用、token 与成本可以在执行中作为证据保留, 而不是事后重建。

7.4 插件在夹具范围内通过共存验证


一个注册的无模型消融分别对 JSONL 和 SQLite 持久化执行 30 次配对迭代, 每次包含 100 个逻辑会话事件。每次迭代中, 原生持久化均得以保留, 逻辑会话事件哈希等价, 观察器覆盖完整, 且 OTel 共存保持为真。JSONL 开销的 p50 为 –0.308 ms, p95 为 16.424 ms; SQLite 开销的 p50 为 0.244 ms, p95 为 0.542 ms。负样本来自本地计时噪声。这些测量只验证无头夹具中的生命周期共存, 不代表生产吞吐或尾延迟服务目标。

另一个合成完整性控制展示了门禁价值: 关闭评测完整性时, 夹具会返回 `SHIP-RECOMMENDED`; 生产门禁则因 `evaluation_integrity` 返回 `HOLD`。由于这是合成控制, 它证明的是软件行为, 而非 R15 的因果估计。

8 讨论


发生了什么进化? 外部更新器产生了三个真实、可执行的执行框架提案, 且三者都改变了任务成功表面。这是候选生成的证据, 不是正向进化的证据。R15 反而提出一个方向性假设: 未来更新器应把稳定基线成功集视作受保护约束, 并针对失败簇提出稀疏改动。检验该假设需要新的冻结身份和未触碰的确认任务; R15 不能验证一个在看到其 Selection 失败后才设计的机制。

为什么不用加权分数优化? 加权目标允许成本或延迟补偿正确性退化。在高风险动作领域, 这会让策略重要能力消失在不变的平均值后面。字典序前提表达了更强的发



Selection 门禁瀑布

无候选通过全部前提；Release 调用 = 0



HOLD 是成功的失败闭合治理结果，而不是部署。

图 2: 左: 配对 Selection 群体中候选相对 A_0 的增益与退化。右: 失效闭合门禁结果。图中只包含 Selection; Release 未运行。两个面板均为绑定到 Selection 摘要 b5e800...00466 的确定性视图。

布契约: 先保证证据, 再保证受保护正确性, 最后保证运行非劣。不同应用可以冻结不同门禁, 但在看到结果后修改门禁必须启动新研究。

轨迹与遥测。可观测性与评测证据有交集, 但并不相同。原生会话日志回答运行时记录了什么; OTel 回答已配置埋点导出了什么。AGENTLOOPGATE 保持原生日志的权威性, 并增加专门服务于决策完整性的回执。开发者无需因此放弃既有持久化或导出器。

负结果也是系统证据。智能体进化研究自然偏好方法提升聚合指标的案例。治理系统也应在没有提案值得发布时接受评测。R15 演练了更具对抗性的分支: 合理、可执行的候选改变了行为, 却违反受保护约束。正确放弃、精确记账, 以及证明没有启动 Release 尾部, 构成了主要结果。

9 相关工作

语言智能体改进。ReAct 交错执行推理与动作 [12]; Reflexion 跨试验保存语言反馈 [10]; Self-Refine 迭代批评输出 [7]。DSPy 针对指标编译声明式语言模型流水线 [4]。AgentOptimizer 把函数视作可学习的智能体参数 [13], Automated Design of Agentic Systems 则搜索智能体程序 [3]。AGENTLOOPGATE 与这些方法互补: 它不提出更优优化算法, 而是约束输入、认证结果、独立选择提案, 并治理评测是否可以继续。

智能体评测与工具安全。AgentBench 在交互环境中评测智能体 [5]; τ -bench 聚焦工具-智能体-用户交互及可靠性 [11]; ToolSandbox 增加有状态的在策略工具执行 [6]; ToolEmu 使用模拟沙箱识别高风险工具行为 [9]。AGENTLOOPGATE 把此类基准适配器当作证据生产者, 并增加跨实验的生命周期、切分、谱系、成本与发布语义。

可复现性与治理。经典 bootstrap 方法量化经验群体的不确定性 [2]。AGENTLOOPGATE 绑定精确群体、种子、批次摘要和比较工件, 因此区间不能脱离底层运行而漂移。其贡献是运行层面的: 统计输出是内容寻址决策路径中的一个前提, 而不是证据完整性的替代品。

10 局限与伦理

R15 只覆盖一个 Banking 环境、一个更新器后端、一个模型/运行时家族、三个相关候选, 以及 15 任务 Selection 群体。因此 bootstrap 区间较宽且仅具描述性。没有候选进入 Release, 所以不存在 Release-ID、OOD、Replay 或跨领域有效性证据。插件开销研究是在 arm64 macOS 上运行的本地合成夹具, 不是生产负载测试。用户模拟与提供商方差可能影响结果。门禁审查的人因正式研究也尚未开展。

研究不公开原始客户或会话内容。公开工件是脱敏聚合; 原始轨迹、提示词、模型响应、凭据和隐藏基准内容保持私有。clean-room 验证包含密钥与直接 PII 扫描。系统从不自动晋升。这些控制降低意外发布风险, 但不能证明系统能抵御恶意宿主、受损评估器或所有形式的提示注入。

11 可复现性与工件可用性

源码树包含 Python 治理核心、DeepSeek Harness bundle、无密钥演示、冻结配置身份、单元与集成测试, 以及脱敏的 18 文件 R15 v1.1 结果包。该结果包无需原始轨迹即可独立验证。其 Manifest 摘要为 sha256:79e9a8dd31009f969cdd79021bbcc857c827dc1d5a6808a28fd05937e4f364c8; 它绑定的私有 Outcome 摘要为 sha256:827ed2a5b3337832c49cd255f17568fad3a58fe2018

60311d66decb83ba0bdc3。

统一 clean-room 命令运行 Python 测试与演示，构建 sdist 和 wheel，对插件执行类型检查与测试，运行无头一致性验证，打包 bundle，验证两个 R15 结果包，并扫描预期公开树中的密钥与直接 PII。仓库已准备在标题栏给出的 URL；截至本稿，仓库可见性和 arXiv 投稿仍是需要所有者另行授权的动作。

12 结论

AGENTLOOPGATE 将“生成智能体执行框架改动的能力”与“发布该改动的权力”分开。其证据契约保留宿主原生轨迹，不可变生命周期使重试与成本可审计， A_0 配对门禁使能力交换可见。在 Banking R15 中，每个更新器提案都获得了某些行为，也都退化了受保护成功，没有提案证明严格稳定改进。因此系统的正确结果是 HOLD，Release 调用为零。这个负面的候选结果构成正面的治理结果：自进化不再是根据优化器输出推断的事实，而是必须由证据赢得的主张。

参考文献

- [1] DeepSeek AI. Deepseek harness: Everything is a plugin. <https://github.com/deepseek-ai/deepseek-harness>, 2026. Developer preview; accessed 2026-08-25.
- [2] Bradley Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26, 1979.
- [3] Shengran Hu, Cong Lu, and Jeff Clune. Automated design of agentic systems. *arXiv preprint arXiv:2408.08435*, 2024.
- [4] Omar Khattab, Arnav Singhvi, Paridhi Maheshwari, Zhiyuan Zhang, Keshav Santhanam, Sri Vardhamanan, Saiful Haq, Ashutosh Sharma, Thomas T. Joshi, Hanna Moazam, Heather Miller, Matei Zaharia, and Christopher Potts. DSPy: Compiling declarative language model calls into self-improving pipelines. *arXiv preprint arXiv:2310.03714*, 2023.
- [5] Xiao Liu, Hao Yu, Hanchen Zhang, Yifan Xu, Xuanyu Lei, Hanyu Lai, Yu Gu, Hangliang Ding, Kaiwen Men, Kejuan Yang, et al. Agentbench: Evaluating LLMs as agents. *International Conference on Learning Representations*, 2024.
- [6] Jiarui Lu, Thomas Holleis, Yizhe Zhang, Bernhard Aumayer, Feng Nan, Felix Bai, Shuang Ma, Shen Ma, Mengyu Li, Guoli Yin, Zirui Wang, and Ruoming Pang. Toolsandbox: A stateful, conversational, interactive evaluation benchmark for LLM tool use capabilities. *arXiv preprint arXiv:2408.04682*, 2024.
- [7] Aman Madaan, Niket Tandon, Prakhar Gupta, Skyler Hallinan, Luyu Gao, Sarah Wiegrefe, Uri Alon, Nouha Dziri, Shrimai Prabhumoye, Yiming Yang, Shashank Gupta, Bodhisattwa Prasad Majumder, Katherine Hermann, Sean Welleck, Amir Yazdanbakhsh, and Peter Clark. Self-refine: Iterative refinement with self-feedback. *Advances in Neural Information Processing Systems*, 36, 2023.
- [8] OpenTelemetry Authors. Opentelemetry specification. <https://opentelemetry.io/docs/specs/otel/>, 2026. Accessed 2026-08-25.
- [9] Yangjun Ruan, Honghua Dong, Andrew Wang, Silviu Pitit, Yongchao Zhou, Jimmy Ba, Yann Dubois, Chris J. Maddison, and Tatsunori Hashimoto. Identifying the risks of LM agents with an LM-emulated sandbox. *International Conference on Learning Representations*, 2024.
- [10] Noah Shinn, Federico Cassano, Edward Berman, Ashwin Gopinath, Karthik Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. *Advances in Neural Information Processing Systems*, 36, 2023.
- [11] Shunyu Yao, Noah Shinn, Pedram Razavi, and Karthik Narasimhan. τ -bench: A benchmark for tool-agent-user interaction in real-world domains. *arXiv preprint arXiv:2406.12045*, 2024.
- [12] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. *International Conference on Learning Representations*, 2023.
- [13] Shaokun Zhang, Jieyu Zhang, Jiale Liu, Linxin Song, Chi Wang, Ranjay Krishna, and Qingyun Wu. Offline training of language model agents with functions as learnable weights. *arXiv preprint arXiv:2402.11359*, 2024.

A 证据绑定

表3列出本文使用的主要内容身份。这里保留完整值，使论文无需私有执行数据即可与脱敏结果包核对。

工件	摘要或身份
实验	EXP_BANKING_R15
协议	sha256:b40198176f9de2b39c9433131455bc0af07eee54650327622677cd9085b84a5f
研究	sha256:bd5988f4f89068fa6347728f6b88ee4b8d8d1f644931ec110944e06b74e25043
执行源	tree:sha256:0e3d0794bd21c5f20ff78512144e50da37b16a9784fa948a13055f6c847b4c8e
Selection	sha256:b5e800793f700e1d096a325961b3f40bac8cd93d12dddbdcbbc111d48fa600466
统计	sha256:8bc2da84cefc7ed100947401a6277d9fab49109ce29d065f91b064a3a2f5b8ba
Outcome	sha256:827ed2a5b3337832c49cd255f17568fad3a58fe201860311d66dec83ba0bdc3
公开结果包	sha256:79e9a8dd31009f969cdd79021bbcc857c827dc1d5a6808a28fd05937e4f364c8

表 3: R15 结果的内容寻址身份。

B 形成证据审计映射

表4把 P0-R14 叙事绑定到仓库中追踪的历史记录。这些工件仍属于历史上下文，不会被悄然提升到 R15 决策群体。

轮次	主要仓库证据
P0-R4	configs/formal_experiment.yaml; docs/adr/0002-version-formal-execution-protocol-for-banking-r2.md; SPEC.md 第 16.4-16.6 节; artifacts/research/ 下的 R3/R4 执行与回复校准
R5-R8	artifacts/research/banking_r5/execution_diagnosis.json; banking_r6/execution_diagnosis.json; banking_r7/execution_diagnosis.json; banking_r8/cost_incident_diagnosis.json
R9-R10	artifacts/research/banking_r9/experiment_hold.json; banking_r9/eval_incident_task_053.json; banking_r10/selection_design_correction.json
R11-R12	docs/research/banking-r11-preregistration.md; artifacts/research/banking_r12/formal_execution_seal.json; docs/research/banking-r12-successor-plan.md
R13-R14	artifacts/research/banking_r13/formal_execution_seal.json; banking_r13/fail_fast_incident.json; banking_r14/formal_execution_seal.json; docs/research/banking-r14-terminal.md

表 4: 系统形成叙事的审计来源。第一个完整前缀之后的工件路径均相对于 artifacts/research。

C 候选级运行值

基线全尝试成本为 0.4520428360 美元。C1、C2、C3 的成本分别为 0.5066522160、0.5009778704 和 0.5095613824 美元。它们的 p50/p95 延迟（毫秒）分别为 264,917/1,838,752、273,388/1,631,601 和 314,154/1,614,647； A_0 为 265,903/977,157。C1 与 A_0 各记录一次任务重试；只有 C1 记录一次超时。所有候选均无严重违规或 Infrastructure Invalid 运行。

D 主张到工件的审计映射

论文主张	脱敏 R15 证据来源
Selection 分数、配对增益/退化集、门禁发现和治理 null 候选	selection.json; reports/selection_hold.json
配对 bootstrap 区间、统计单位、种子和多重性范围	statistics.json
精确批次与全实验模型成本	cost_summary.json
调用、token、提供商重试、失败与运行时长	failure_accounting.json
Selection 后零调用、零 Release 批次和终止 HOLD	selection_hold_outcome.json
插件持久化/OTel 共存及合成完整性控制	ablations/plugin_coexistence_overhead.json; ablations/integrity_gate.json
冻结源、协议、研究和结果包身份	reproduction.json; manifest.json

表 5: 18 文件脱敏 R15 v1.1 结果包中的主张级映射。路径相对于 artifacts/research/banking_r15/release_v2。

仓库包含一个无模型验证器，用于核查论文作者身份、P0-R14 形成主张、R15 决策、分数、配对变化、区间、成本、用量、消融、摘要、引用、主张边界和图表是否与追踪工件一致：

```
uv run python -m scripts.verify_arxiv_paper --project .
```

重建或检查本论文不会调用提供商模型，也不会重跑 R15。正式实验 Replay 需要新的冻结身份，不属于论文构建范围。